

Влияние порядка действий на качество плана

Выполнил: Личковаха Даниил Андреевич 24581-мм

Куратор: Попцов Александр Владимирович

Научный руководитель: Вяткин Артём Андреевич

Санкт-Петербург 2026



Санкт-Петербургский
государственный
университет

Введение

- рассматривается задача составления планов с использованием PDDL (Planning Domain Definition Language)
- В качестве планировщика используются LLMs
- Необходимо проверить гипотезу о том, что порядок действий в домене влияет на итоговое качество плана



Что такое PDDL — это способ описывать задачи

Есть 4 главные сущности:

1. Domain (домен) — какие действия вообще существуют
2. Problem (проблема) — конкретная ситуация
3. State (состояние) — что сейчас истинно
4. Plan (план) — последовательность действий для достижения цели



Пример

домен

ACTION move(robot, from, to)
ACTION
ACTION

PRECONDITIONS:
robot находится в from

EFFECTS:
robot больше не в from
robot теперь в to

проблема

OBJECTS:
robot1
roomA
roomB
box1

INITIAL STATE:

robot1 в roomA
box1 в roomA
robot1 свободен

GOAL:

box1 в roomB

план

1. pick_up(robot1, box1, roomA)
2. move(robot1, roomA, roomB)
3. drop(robot1, box1, roomB)

Цель и предмет исследования

The title 'Цель и предмет исследования' is centered at the top. Two large, hand-drawn style arrows originate from the words 'Цель' and 'предмет' respectively, pointing downwards and outwards to the two text blocks below.

измерить, насколько
сильно меняется
качество плана при
разных порядках
действий в одном и том
же домене.

зависимость качества
сгенерированного плана
от порядка
перечисления действий
в PDDL-описании домена
при неизменных
начальном
состоянии, целевом
состоянии и семантике
действий.



Всего было 20 задач и для каждой задачи строились 6 вариантов pddl-

домена:

1. **canonical** - исходный порядок действий в домене;

2. **disp_1** - частично изменённый порядок действий с умеренной степенью

расхождения относительно canonical;

3. **disp_2** - частично изменённый порядок действий с более сильной степенью

расхождения относительно canonical;

4. **disp_3** - полный обратный порядок действий относительно canonical;

5. **plan_front** - вариант, в котором действия, встречающиеся в эталонном плане

задачи, вынесены в начало домена в порядке их первого появления;

6. **plan_scatter** - вариант, в котором те же действия из эталонного плана располагаются в обратном порядке и равномерно рассеиваются среди остальных

действий домена.

***также для каждого варианта было проведено 15 зависимых прогонов, чтобы уменьшить эффект случайности

Используемые метрики




- executability
- reachability
- conditional reachability
- optimality ratio
- plan length
- first failure step
- tokens (completion, reasoning, total)
- duration_sec




Обратимся к результатам

- на уровне описательной статистики видно, что deepseek-v4-flash в среднем даёт существенно более высокую долю валидных планов, чем gpt-oss-120b.
- для deepseek наибольшее снижение качества наблюдается при полном реверсе порядка действий (disp_3), тогда как для gpt-oss-120b слабым местом оказываются почти все перестановочные варианты, кроме plan_front.







First Failure Step (available, 34%) by order




Plan Length (100%) by order



Conditional Reachability (51%) by order



Completion Token Breakdown (100%) by order



Результаты статистических тестов для deepseek-v4-flash

Достижимость:

- сравнение дало **снижение reachability с 0.5367 до 0.3933**.
- Тест Мак-Немара показал $p = 0.000055$, $p_{\text{Holm}} = 0.000275$.

Это означает, что полный реверс порядка действий статистически значимо ухудшает вероятность достижения цели.

Исполнимость:

- наблюдалось **снижение executability с 0.6433 до 0.5467**
- Тест Мак-Немара показал $p = 0.007585$,
- $p_{\text{Holm}} = 0.037924$

Следовательно, сильная перестановка затрудняет для модели даже выход на исполнимую последовательность действий.

Для остальных сравнений canonical -> disp_1, canonical -> disp_2.... статистически значимых различий по reachability и executability после поправки Холма обнаружено не было. Модель в целом относительно устойчива к умеренным изменениям порядка действий и заметно деградирует только при наиболее сильной перестановке.

***По модели deepseek-v4-flash статистически значимые различия после поправки Холма были обнаружены прежде всего для сильного порядка disp_3 (в сравнении с canonical).



Результаты статистических тестов для gpt-oss-120b

Достижимость:

- canonical -> disp_1: 0.1300 против 0.0833, $p = 0.004344$, $p_{\text{Holm}} = 0.013031$;
- canonical -> disp_2: 0.1300 против 0.0700, $p = 0.000534$, $p_{\text{Holm}} = 0.002134$;
- canonical -> disp_3: 0.1300 против 0.0400, $p < 0.000001$, $p_{\text{Holm}} = 0.000002$;
- canonical -> plan_scatter: 0.1300 против 0.0867, $p = 0.010622$, $p_{\text{Holm}} = 0.021244$.

Исполнимость:

- canonical -> disp_3: 0.4167 против 0.3167, $p = 0.006352$, $p_{\text{Holm}} = 0.031758$.
- Для disp_1 и disp_2 наблюдалось ухудшение и по executability, но после поправки Холма эти различия не достигли уровня значимости ($< 5\%$).



Интерпретация качественных различий между моделями

- У deepseek-v4-flash `parse_error` практически не встречается: его доля по вариантам составляет от 0.0 до 0.017. Основной тип неудачи здесь - `state_execution_error`. Это означает, что модель обычно соблюдает формат выходного плана, но чаще ошибается на уровне логики последовательности действий и их предусловий.
- У gpt-oss-120b доля `parse_error` существенно выше: от 0.213 в `canonical` до примерно 0.310-0.327 в `disp_1`, `disp_2`, `disp_3` и `plan_scatter`. Таким образом, для этой модели изменение порядка действий влияет не только на качество планирования как такового, но и на стабильность формата ответа.
- Важно, что по длине плана и отношению оптимальности статистически значимых различий почти не наблюдается ни у одной модели. Следовательно, главный эффект порядка проявляется не в том, насколько хорош уже найденный корректный план, а в том, насколько часто модель вообще выходит на валидную траекторию. Иначе говоря, порядок действий влияет прежде всего на вероятность успешного запуска, а не на качество решения при условии успеха.



Выводы

1. Порядок действий в PDDL-домене действительно **влияет** на качество плана, генерируемого языковой моделью, несмотря на семантическую эквивалентность всех вариантов домена.
2. **Степень** этого влияния **зависит от модели**. deepseek-v4-flash оказался значительно устойчивее к умеренным перестановкам, тогда как gpt-oss-120b продемонстрировал выраженную чувствительность к порядку описания действий.
3. **Наиболее сложным** вариантом перестановки для обеих моделей **является обратный порядок** относительно исходного (disp_3), однако у gpt-oss-120b заметный негативный эффект проявляется и для других порядков.
4. **Эффект порядка проявляется главным образом в вероятности получить исполнимый и достигающий цели план**. Качество уже успешных решений, измеряемое длиной плана и отношением оптимальности, меняется значительно слабее и не демонстрирует устойчивых статистически значимых различий.
5. Для deepseek-v4-flash характерны в основном ошибки исполнения состояния, тогда как для gpt-oss-120b существенную роль играют и ошибки разбора. Это может свидетельствовать о **различных механизмах деградации качества у моделей** при одном и том же изменении порядка представления домена.

